Stilski transfer teksta u duhu Ive Andrića

Nikol Vidaković, RA232/2023

Fakultet tehničkih nauka, Novi Sad

Inteligentni sistemi

1. Opis problema

Cilj projekta je automatska transformacija neutralnih srpskih rečenica u rečenice koje stilski podsećaju na prozu Ive Andrića: bogate epitetima, metaforama, filozofskim tonom i karakteristično dugim, slojevitim rečenicama. Model je implementiran od nule u PyTorch-u, bez korišćenja gotovih pre-treniranih modela, a dataset je ručno kreiran. Loš krajnji rezultat generisanja je u skladu sa očekivanjem za ovakvu veličinu dataseta; fokus projekta je na razumevanju i dokumentovanju procesa.

2. Arhitektura modela

Implementiran je Encoder-Decoder Transformer u fajlu src/model.py. Finalna arhitektura sadrži sledeće komponente:

- GroupedQueryAttention (GQA) - zamenjuje standardni MultiHeadAttention u svim attention slojevima, uključujući self-attention i cross-attention. 4 Q glave dele 2 K/V glave, što smanjuje broj parametara.
- RoPE (Rotary Positional Encoding) - pozicijska informacija se ugrađuje direktno u mehanizam pažnje rotacijom Q i K vektora, umesto dodavanja fiksnog sinusnog vektora na embedding.
- FeedForward - dvoslojna mreža sa GELU aktivacijom (d_ff = 1024, standardno 4× d_model).
- Pre-LN konfiguracija - normalizacija se vrši pre attention bloka umesto posle, što daje stabilniji trening na malim datasetima.
- Maskiranje - src_mask ignoriše PAD tokene, tgt_mask je kauzalna maska koja sprečava dekoder da vidi buduće tokene tokom treninga.

Parametar	Vrednost
d_model	256
Broj Q glava (GQA)	4
Broj K/V glava (GQA)	2
d_ff	1024
num_layers	3
dropout	0.3
Ukupan broj parametara	~7.65M

Trening: CrossEntropyLoss (ignoriše PAD tokene), AdamW optimizer (lr=0.0001, weight_decay=0.01), gradient clipping (max_norm=1.0). Generisanje: autoregresivno token po token, Top-K sampling (k=50), temperatura T=0.8.

3. Dataset i tokenizacija

Dataset se sastoji od 550 parova rečenica u formatu CSV (separator ';', UTF-8), sa kolonama id, original_text (Andrićeva rečenica) i neutral_text (neutralna verzija). Dataset je kreiran u dve faze:

- 350 autentičnih parova — direktni citati iz Andrićevih dela sa ručno pisanim neutralnim verzijama.
- 200 sintetičkih parova (ID 351–550) — generisani u Andrićevom stilu i manuelno pregledani za ekavicu, ćirilicu (sve je prebačeno na latinicu) i dužinu neutralnih rečenica (neutralne rečenice su u proseku 10-12 reči).

Dataset je podeljen na 440 trening / 110 validacionih parova (80/20, seed=42).

Za tokenizaciju je isprobano nekoliko pristupa.

Word-level tokenizer (Eksperimenti 1 i 2) tretira svaku reč kao zasebni token; nedostatak je što srpska morfologija (padeži, rodovi) stvara previše retkih tokena.

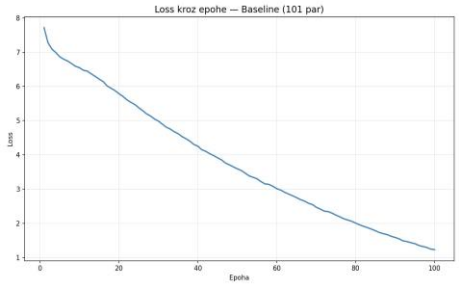
Pokušaj treniranja SentencePiece tokenizera sa Unigram algoritmom nije dao dobre rezultate jer je dataset premali: reč 'Pada' rastavlja se na karaktere umesto na smislene podreči.

Stoga je usvojen pre-trenirani mT5 tokenizer (google/mt5-small) koji već poznaje srpsku morfologiju, sa kompaktnim remapiranjem: od 250.100 originalnih tokena uzimamo samo 3531 koji se pojavljuju u datasetu, čime se embedding tabela smanjuje sa ~64M na ~900K parametara.

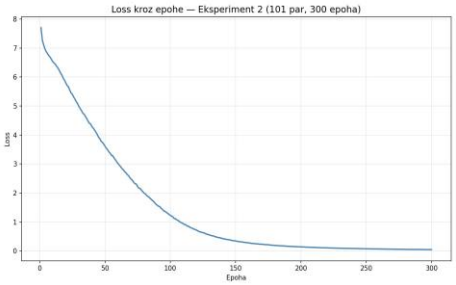
4. Eksperimenti i tok istraživanja

4.1 Pregled eksperimenata i loss grafovi

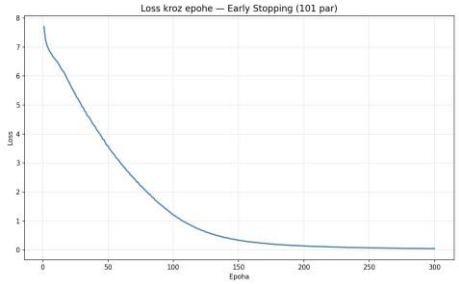
Svaki eksperiment bio je motivisan nalazima prethodnog. U nastavku su prikazani loss grafovi svih faza istraživanja sa kratkim objašnjenjima.



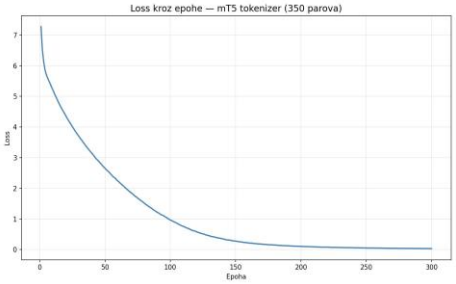
Slika 1 - Eksperiment 1: baseline (101 par, 100 epoha, word-level). Loss opada linearno i ne dostiže stagnaciju — model još uči na kraju treninga.



Slika 2 - Eksperiment 2: produženi trening (101 par, 300 epoha). Loss pada na 0.04, što je jasan znak overfitting-a.

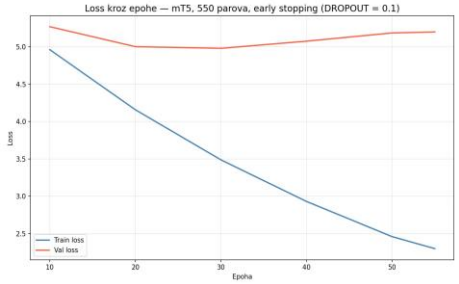


Slika 3 - Early stopping bez val skupa: loss nastavlja da pada jer model uvek može bolje da zapamti trening primere; early stopping se ne aktivira smisleno.

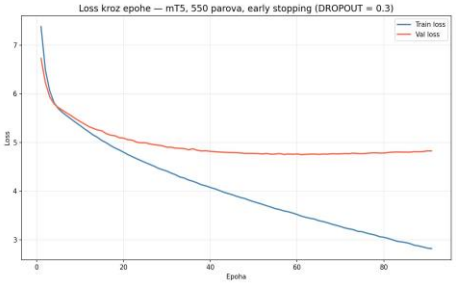


Slika 4 - Eksperiment 3: mT5 tokenizer (350 parova, 300 epoha, bez val splita). Isti problem: loss pada na 0.03, overfitting ostaje.

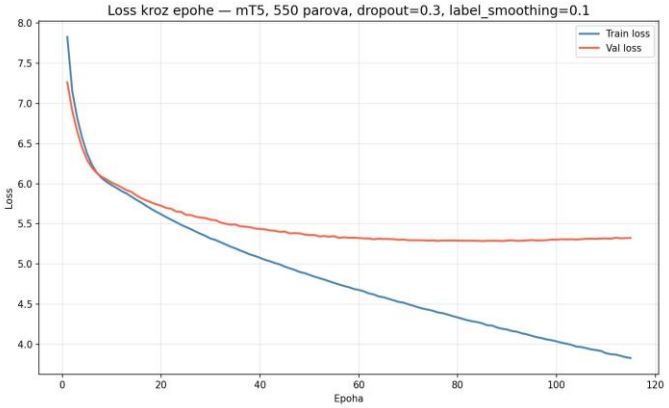
Nakon uvođenja train/val splita (550 parova, 80/20) early stopping je napokon počeo da funkcioniše. Isprobane su različite konfiguracije:



Slika 5 - dropout=0.1: val loss stagnira i počinje da raste, agresivniji overfitting.



Slika 6 - dropout=0.3: val loss stabilniji, model duže ostaje u korisnoj zoni (val loss 4.75, epoha ~91).

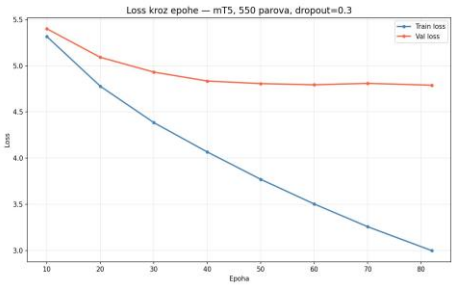


Slika 7 - Label smoothing (dropout=0.3, label_smoothing=0.1): povećava apsolutne vrednosti lossa i otežava poređenje između konfiguracija, pa je izbačen.

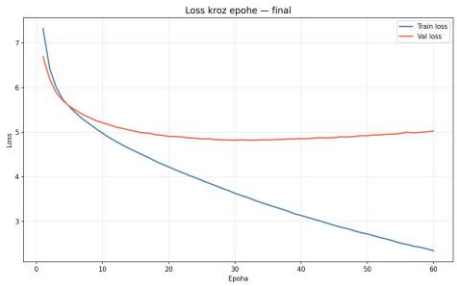
Label smoothing je uklonjen jer povećava apsolutne vrednosti lossa i onemogućava direktno poređenje sa prethodnim eksperimentima. Finalna konfiguracija bez label smoothinga (dropout=0.3, batch=16) je nazvana prefinal model.

4.2 Poređenje prefinal i finalnog modela

Prefinal model (sinusno/kosinusno pozicijsko kodiranje + standardni MHA) i finalni model (RoPE + GQA) trenirani su na istom datasetu sa identičnom konfiguracijom — jedina razlika je u arhitekturi.



Slika 8 - Prefinal model (sin/cos PE + MHA): val loss 4.75, early stopping u epohi ~91.



Slika 9 - Finalni model (RoPE + GQA): val loss 4.82, early stopping u epohi 60.

Val loss finalnog modela je neznatno viši (4.82 vs 4.75): sa samo 110 validacionih parova, val loss može da osciluje za ±0.05-0.10 između pokretanja samo zbog slučajnog splita podataka. Znači da razlika od 0.07 nije pouzdana: mogla bi biti i 0 ili čak obrnuta u sledećem pokretanju. Finalni model konvergira brže (60 vs 91 epoha), što se može pripisati efikasnijoj reprezentaciji pozicija kroz RoPE. Uprkos nešto nižem val lossu prefinal modela, odabrana je finalna arhitektura jer uvodi moderne tehnike (RoPE, GQA) prisutne u aktuelnim LLM modelima, bez merljive degradacije performansi.

5. Rezultati generisanja

Iste rečenice su testirane kroz ključne eksperimente radi poređenja napretka. Treba napomenuti da je prelaz sa word-level tokenizatora na mT5 subword tokenizatora fundamentalno promenio prirodu grešaka. Naime, mT5 model mora istovremeno naučiti i stilski transfer i rekonstrukciju validnih srpskih subword sekvenci, što je znatno teži zadatak.

Ulaz	Eksperiment 1 - 100 epoha	Eksperiment 2 - 300 epoha	Finalni model (RoPE + GQA)
Pada kiša na grad.	samo se nijema nikad u jednu boju i nadmoć u trenutku ima čestitih to nije od vrednosti smo da se upotpunjuju kao spomenik da se i naš bolje svršiti.	svi su mi ljudi i te kako potrebni. svi, od one starice koja me je slast. ona daje i pri svemu tome često se svojoj lepoti, u stvari, ja samo ono što je dobro ni u nama iščezava a tek poneki vršak i stihijskom i prohteva.	nekoherentne subword sekvence (de – ena – naenr-t ...)
Čovek hoda	tvoji prihodi je	dvaput u životu čovek	nekoherentne subword

ulicom.	sposoban se, ga za obrađivanje i ne se često, društva u kotlovima nemir; živo stvorenje. mu je stvoreno, nezdrave kad smo će već između palca	je izložen jakom iskušenju da suviše govori o sebi. prvo je mladićko doba, sa njegovom bujnošću i nemirima svake vrste, a drugo starački doba, sa manje ili više izrazitim i mrači kad leže oblaci će ti najbolje kazati.	sekvence (de m (s term...)
Sunce zalazi iza brda.	svašta je brujanje svoje svoj ni najtvrđem tome, i istakoše žuto, izbrazdano kad snaga to se mnogo svega onoga i nezdrav	jer, šta su sitne muke i odricanja koja hoda od mene.	nekoherentne subword sekvence (! l-i S)eg u la...)

Eksperiment 1 (word-level, 100 epoha): model generiše andrićevski vokabular ('nijema', 'nadmoć', 'stvorenje', 'izbrazdano') ali bez gramatičke koherentnosti; model još nije naučio obrasce.

Eksperiment 2 (word-level, 300 epoha): gramatički ispravnije, ali model reprodukuje fraze direktno iz dataseta, što je potvrđeno ručnom proverom u CSV-u.

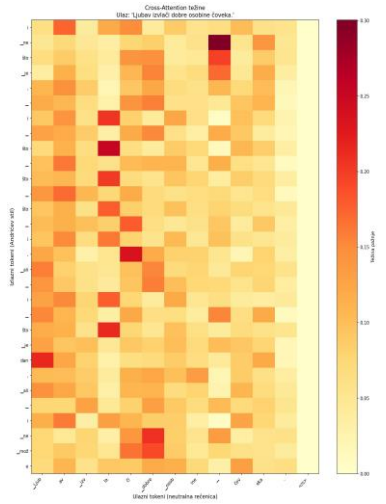
Finalni model (mT5 + RoPE + GQA): nekoherentne subword sekvence; uzrok je veličina dataseta od 550 parova, a ne greška u arhitekturi, što potvrđuje i analiza attention mehanizma u poglavlju 6.

6. Vizuelizacija cross-attention mehanizma

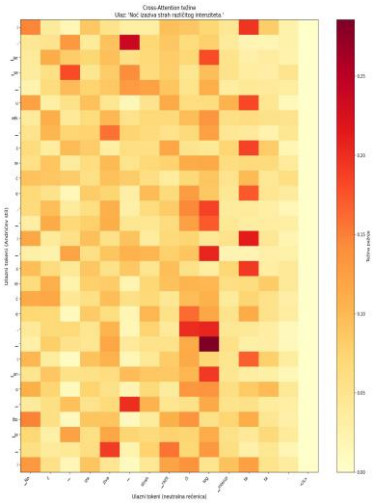
Implementirana je vizuelizacija cross-attention težina iz poslednjeg sloja dekodera (src/attention_viz.py). Heatmapa prikazuje distribuciju pažnje pri generisanju svakog izlaznog tokena: redovi su izlazni tokeni (Andrićev stil), kolone su ulazni tokeni (neutralna rečenica), a intenzitet boje odgovara intenzitetu pažnje. Sve vizuelizacije su iz finalnog modela (RoPE + GQA).

6.1 Poznate rečenice — iz dataseta

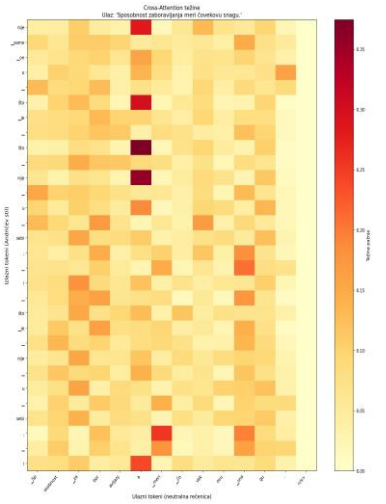
Na rečenicama koje su bile deo trening skupa model pokazuje jasne centre pažnje na semantički ključnim tokenima, što potvrđuje da cross-attention mehanizam funkcioniše ispravno.



Slika 10 - 'Ljubav izvlači dobre osobine čoveka.' Fokus na 'dobre' i delove reči 'čoveka'.



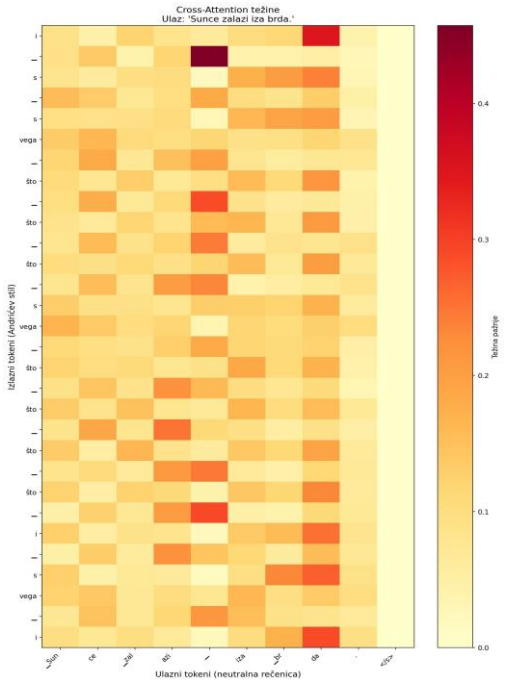
Slika 11 - 'Noć izaziva strah različitog intenziteta.' Pažnja raspoređena na više semantički relevantnih tokena.



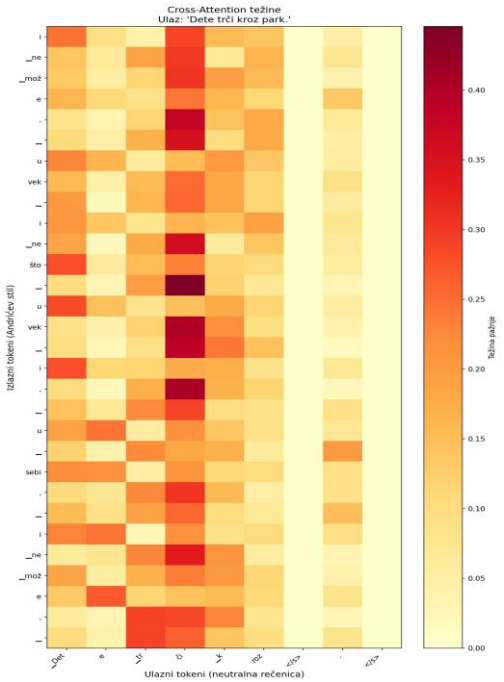
Slika 12 - 'Sposobnost zaboravljanja meri čovekovu snagu.' Vidljiv fokus na 'meri' i 'snagu'.

6.2 Nepoznate rečenice — van dataseta

Na rečenicama koje model nije video tokom treninga generisanje je repetitivno, ali cross-attention i dalje čita ulaz : pažnja je usmerena na relevantne ulazne tokene. Ovo potvrđuje da je problem veličina dataseta, a ne kvar u arhitekturi.



Slika 13 - 'Sunce zalazi iza brda.' Attention fokusiran na 'ce' i 'zal' (delovi od 'Sunce zalazi'), ali model generiše repetitivne tokene.



Slika 14 - 'Dete trči kroz park.' Difuzniji attention bez jasne strategije: model nije video slične primere tokom treninga.

Zaključak

Projekat demonstrira kompletan istraživački pipeline kroz pet eksperimenata koji su se nadovezivali jedan na drugi. Word-level tokenizacija i trening bez validacionog skupa dali su overfitting čak i sa early stoppingom - loss ispod 0.1 na malom datasetu signal je memorisanja, ne učenja. mT5 subword tokenizacija je bolji pristup za srpski jezik, ali zahteva pravi train/val split. Dropout 0.3 dao je bolju regularizaciju od dropout 0.1, dok je label smoothing odbačen zbog otežanog poređenja rezultata.

Finalni model (Encoder-Decoder Transformer sa RoPE i GQA, ~7.65M parametara) postiže val loss 4.82 sa early stoppingom u epohi 60. Vizuelizacija cross-attention mehanizma potvrđuje da model ispravno čita ulaz: nekoherentno generisanje je isključivo posledica veličine dataseta od 550 parova. Sa više podataka i GPU treningom, sistem bi mogao da generiše smislenije stilske transformacije.